

Playing hard exploration games by watching YouTube

DeepMind



问题介绍

- 当环境奖励特别稀疏的时候，强化学习方法通常很难训练(traditionally struggle)。一个有效的方式是通过人类示范者(human demonstrator)提供模仿轨迹(imitate trajectories)来指导强化学习的探索方向。
- 不同的视频来源通常有细微的差异(domain gap)，只有在完全相同的环境中(尺寸、分辨率、纵横比、颜色等等)获得状态信息 S ，同时获得对应需要模仿的动作信息 a ，甚至环境回报 r ，然后构成状态动作对 (S,a) 才能进行模仿学习。

两个问题

1. 游戏镜头不匹配(unaligned gameplay footage)
2. 没有动作标签(unlabeled)

两个问题

1. 游戏镜头不匹配(unaligned gameplay footage)
2. 没有动作标签(unlabeled)

解决方法

- 1.通过自监督(self-supervised)的学习方式构造视频到状态抽象特征的映射，消除不同视频来源的细微差异造成的影响。
- 2.用输出的抽象特征作为状态S，结合模仿学习和强化学习探索最优动作。

该方法在Montezuma's Revenge、Pitfall、Private Eye三个游戏中取得了超越人类水平的效果。

不匹配问题(domain gap)




Figure 1: Illustration of the domain gap that exists between the Atari Learning Environment and YouTube videos from which our agent is able to learn to play MONTEZUMA'S REVENGE. Note different size, resolution, aspect ratio, color and addition of visual artifacts such as text and avatars.

思路

- 构造一个辅助任务让神经网络(embedding network)去学习，希望网络可以学到关键的特征而忽略不必要的差异。
- 由于没有任务标签，于是采用自监督(self-supervision)的方式构造标签并进行训练。

方法

- Temporal distance classification(TDC)
- Cross-modal temporal distance classification(CMC)

Temporal distance classification(TDC)

- 利用同一视频中，视频序列的时间关系构建一个时间标签的监督学习任务,即让网络去预测同一视频中任意抽取的两帧图像之间的时间差分距离 Δt 。
- 作者解释说，这个任务需要网络理解不同帧图像在时间上的转移关系，有助于网络学习到环境和agent交互过程中的环境变化规律。

具体构造:

按照时间差分距离分成6个区间类别 $d_k \in \{[0], [1], [2], [3 - 4], [5 - 20], [21 - 200]\}$
考虑两帧图像 $v, w \in I$ ，让网络学会预测两帧图像的时间差区间 d_k

visual embedding function $\phi : I \rightarrow R^N$

classifier function $\tau_{td} : R^N \times R^N \rightarrow R^K$

$$\hat{y}^i = \tau_{td}(\phi(v^i), \phi(w^i))$$

Cross-modal temporal distance classification(CMC)

- 该方法融入声音信息，将视频和声音进行匹配，预测两者之间的时间差。
- 作者解释说游戏的音频信息通常和动作事件高度相关，比如跳、捡到道具等等，这个任务有助于网络理解游戏中的重要事件。

具体构造:

视频数据记为 $v \in I$ ，音频数据记为 $a \in A$ 。

audio embedding function $\psi: A \rightarrow R^N$

$$\hat{y}^i = \tau_{cm}(\phi(v^i), \psi(a^i))$$

最终方法结合了TDC和CMC两种方法：




Figure 3: Illustration of the network architectures and interactions involved in our combined TDC+CMC self-supervised loss calculation. The final layer FC2 of ϕ is later used to embed the demonstration trajectory to imitate. Although the Atari Learning Environment does not expose an audio signal to our agent at training time, the audio signal present in YouTube footage made a substantial contribution to the learnt visual embedding function ϕ .

评估方法

网络训练结束后，需要一种方式来评价编码网络的特征提取能力。受CycleGAN启发，作者提出了循环一致(cycle-consistency)评估方法。


假设有两段长度为 N 的序列片段 $V = \{v_1, v_2, \dots, v_n\}$ 和 $W = \{w_1, w_2, \dots, w_n\}$ 。在提取的特征空间上定义欧氏距离 d_ϕ , $d_\phi(v_i, w_j) = \|\phi(v_i) - \phi(w_j)\|_2$ 。

评估方式如下：

- 先从 V 中挑选一帧数据 v_i ,找出 W 中和 v_i 距离最近的一帧, $w_j = \arg \min_{w \in W} d_\phi(v_i, w)$ 。
- 再从 W 中找出一帧和 w_j 距离最近的一帧, $v_k = \arg \min_{v \in V} d_\phi(v, w_j)$ 。
- 如果 $v_i = v_k$,我们就称 v_i 是循环一致的(cycle-consistency)。
- 同时再定义一个——对应的特征匹配能力的指标，记为 P_ϕ 。 P_ϕ 表示在特征空间 ϕ 上特征数据 $v \in V$ 是循环一致(cycle-consistent)的百分比。

此外，根据定义也可以在 ϕ 上定义三重循环一致(3-cycle-consistency)和匹配能力指标 P_ϕ^3 。这要求 v_i 在三个序列 V, W, U 上满足 $V \rightarrow W \rightarrow U \rightarrow V$ 和 $V \rightarrow U \rightarrow W \rightarrow V$ 。

实验效果



Embedding Method	P_ϕ	P_ϕ^3
l_2 pixel distance	30.5	08.4
single-view TCN [29]	32.2	15.9
TDC (ours)	42.0	23.0
L^3 -Net [3]	27.3	10.9
CMC (ours)	41.7	23.6
combined (TDC+CMC)	44.2	27.5

Figure 4: Cycle-consistency evaluation considering different embedding spaces. We compare naive l_2 pixel loss to temporal methods (TDC and single-view TCN) and cross-modal methods (CMC and L^3 -Net). Combining TDC and CMC yields the best performance for both 2 and 3-cycle-consistency, particularly at deeper levels of abstraction (e.g. no performance loss using FC1 or FC2).

t-SNE可视化



One-shot imitation from YouTube footage

- 目前已经将游戏视频和agent的环境状态对应上，但依然没有动作和回报信息。
- 选择其中一个视频让网络学习。学习思路是让agent在环境中探索动作，如果得到的状态和视频的状态匹配，说明模仿到位，给一个大于0的回报，否则不给回报，也不给惩罚。

具体方法

- 每隔 N 帧($N = 16$)设置一个检查点(checkpoint),设置模仿回报

$$r_{imitation} = \begin{cases} 0.5 & \text{if } \bar{\phi}(v_{agent}) \cdot \bar{\phi}(v_{checkpoint}) > \gamma \\ 0.0 & \text{otherwise} \end{cases}$$

- 其中 γ 是衡量匹配度的阈值, $\bar{\phi}(v)$ 经过均值方差归一化
- 训练方法上, 直接使用传统的强化学习算法: 分布式的A3C算法(distributed A3C RL agent IMPALA)。

训练结果

	MONTEZUMA'S REVENGE	PITFALL!	PRIVATE EYE
Rainbow [19]	384.0	0.0	4,234.0
ApeX [22]	2,500.0	-0.6	49.8
DQfD [20]	4,659.7	57.3	42,457.2
Average Human [38]	4,743.0	6,464.0	69,571.0
Ours ($r_{\text{imitation}}$ only)	35,926.1	53,407.6	98,212.5
Ours ($r_{\text{imitation}} + r_{\text{env}}$)	41,098.4	60,258.9	98,763.2

Table 1: Comparison of our best policy (mean of 200 evaluation episodes) to previously published results across MONTEZUMA'S REVENGE, PITFALL! and PRIVATE EYE. Our agent is the first to exceed average human-level performance on all three games, even without environment rewards.

游戏示例



游戏示例

