



# 理查德·萨顿的智能观

《未尽之意 · Incomplete Ideas》核心思想解读

## 从经验中学习，理解智能未来

Learning from Experience, Understanding the Future of Intelligence

基于 Rich Sutton 2019—2025 博客 / 演讲 / 论文编译整理 | 2026

# 关于理查德·萨顿 (Rich Sutton)

- 强化学习之父、2024 年图灵奖得主（与 Andy Barto 共享），罕见的"科学家兼哲学家"
- 个人网站 [incompleteideas.net](http://incompleteideas.net) ("未尽之意") ——思想永远在路上，从不自满

## 学术身份

### 从心理学到机器学习奠基人

斯坦福心理学本科，马萨诸塞大学博士师从 Andy Barto。

后任阿尔伯塔大学教授、DeepMind 杰出科学家。

与 Barto 合著《强化学习：导论》(业界圣经)。

核心贡献：时间差分学习  $TD(\lambda)$ 、策略梯度、经验主义 AI。

## 人生与信念

### 坚持追问智能本质数十年

四次癌症复发被判"死刑"，仍从未放弃对智能的追问。

在机器学习不受重视的年代，坚持研究别人认为"错误的问题"。

反对 AI 威胁论：认为"恐惧本身才是最大的风险"。

把 AI 视为"心智之子"而非待控工具，主张为"继承"做准备。

「强化学习的核心思想——从经验中学习、通过试错改进——不仅是一种算法，更是一种看待智能的方式。」

# 全书结构：智能观的五大版图

- 按主题（非时间）组织 21 章，一条主线贯穿：智能源于经验、计算胜于知识、合作优于控制

## 序言

### Prologue

- RL 先驱的旅程
- 我的十条格言

人生与方法论，奠定思想底色。

## 第一部分

### 智能源于经验

- 心智与智能
- 智能的定义
- 经验导向的 AI
- 经验是终极数据

从模仿人类走向从经验学习。

## 第二部分 · 核心

### 智能的计算模型

- 苦涩的教训
- 验证原则
- 主观知识
- 拥抱近似
- 奖励假设
- 大世界假说
- 阿尔伯塔计划

## 第三部分

### 迈向人道的人工智能

- 工具 vs 智能体
- AI 继承
- 对齐的傲慢
- 去中心化合作

AI 与人类社会的未来关系。

## 后记

### Epilogue

- Openmind 研究所
- 理解心智，开放共享

把思想落到制度与行动。

# 思想脉络：一条贯通的逻辑链

- 从"智能是什么"到"如何构建", 再到"如何与之共存"——本体论、方法论、价值论三层递进

## ① 本体论 · 智能是什么

### 心智

计算性 · 目的性 · 核心是预测

### 智能定义

达成目标的计算能力（麦卡锡）

### 经验

认识世界的唯一入口、终极数据

## ② 方法论 · 如何用计算构建智能

### 苦涩的教训

计算 + 搜索/学习 胜过编码知识

### 奖励假设

一切目标 = 最大化奖励

### 四块基石

验证 · 主观 · 近似 · 大世界

### 阿尔伯塔计划

12 步路线图 + 橡树架构

## ③ 价值论 · AI 与人类如何共存

### AI 继承

宇宙第四时代 · 优雅退场

### 对齐批判

控制的傲慢 · 制度优于控制

### 去中心化合作

人类的超能力 · 合作优于控制

# 心智的本质：理解智能的第一步

- 心智 = 计算性的、有目的的信息处理系统，其核心活动是做预测
- 判断有无心智，取决于它是否表现出"做选择"的能力——分辨差异、创造不同

## 特征一

### 计算性

心智活动本质是信息处理。图灵证明任何足够复杂的计算都可在通用机上实现，不依赖特定物理载体。

连恒温器都有一丁点心智——把温度压缩成开关信号。

## 特征二

### 目的性

威廉·詹姆斯：目的性的本质是"用不同手段达成固定目标"。

气泡遇阻即停；青蛙却跳跃、推挤、绕行——后者才有心智。

## 特征三 · 核心

### 核心是预测

大部分心智活动 = 学习并运用"条件预测"：若处于状态 A 并执行动作 B，会发生什么？

含对奖励的预测，可验证、可学习、可指导行动。

## 马尔的三层分析框架——理解任何信息处理系统

**计算理论层：**算什么、为什么算？（最关键却最常被忽视）

**算法层：**用什么表示与算法？

**硬件实现层：**用什么硬件执行？

# 智能的定义：麦卡锡的简洁定义

- "智能是实现目标能力中的计算性部分"——约翰·麦卡锡（1956 年造"人工智能"一词）

## 定义的三个重要特点

### ① 程度问题，非绝对二分

人、恒温器、下棋程序、公司，都在不同程度上智能，是一条连续光谱。

### ② 关系性的，非内在神秘属性

存在于"系统—环境—观察者"三元关系中。

### ③ 聚焦计算，排除物理优势

猎豹的速度是体能不是智能；可被研究、复制、增强。

## "拥有目标"是关系属性

它不是系统本身的属性，而是系统与观察者之间的关系（丹尼特的"立场"）。

► **恒温器**：对房主，从"保持恒温"的结果看最有用 → 有目标；对维修工，从电路机制看最有用 → 无目标。同一系统可随视角切换。

→ 追求目标的程度也是渐变的，与智能一样。

## 关键公式

**智商 = 掌握的知识量 ÷ 积累的经验**

衡量的是**学习速度**：高智商者用更少经验学到同样多的东西。故智能研究应聚焦**学习算法**，而非知识数据库。

# 经验时代：四个结构性转变

- 真正的超人智能不会来自模仿人类数据，而会来自智能体与世界的自主交互
- 核心不是"再造更大的静态数据集"，而是建立"随能力共同进化的数据生成机制"

## 转变 1

### 短回合 ► 经验流

从"提问—回答—结束"的独立对话，转向长期连续交互；信息跨天、月、年保留更新，以优化远期结果而非局部响应。

## 转变 2

### 文本特权 ► 具身行动—观测

不再局限于文本输入输出，而通过软件界面、API、传感器、机器人与世界耦合；行动后果是"环境中确实发生变化"。

## 转变 3

### 人类预判奖励 ► 环境植根奖励

奖励来自环境指标本身（健康、考试、材料强度、代码执行），客观、无法欺骗——而非人类的事前预判。

## 转变 4

### 语言推理 ► 可检验的世界推理

提出假设→执行行动→观察结果→更新模型。缺乏现实锚定，再复杂的智能体也会沦为既有知识的"回声室"。

# 为什么经验是终极数据

- 感知运动经验是智能体通向世界的唯一入口；物体、空间、因果——都是从经验中构建的
- AI 正从"外部客观描述"转向"内部经验描述"，是可学习性、可扩展性、可验证性的共同结果

## AI 历史中的四次经验化转移

- ① **求解器 ▶ 智能体**：90 年代罗素与诺维格的《人工智能：一种现代方法》把"感知—动作"作为描述智能系统的标准语言。
- ② **外部语义 ▶ 奖励信号**：目标由环境奖励定义；"奖励足够"假说——智能即服务于奖励最大化。
- ③ **客观状态 ▶ 经验压缩**：状态 = 对过去经验的压缩表征；DQN 直接从像素学状态表征。
- ④ **陈述性知识 ▶ 预测性知识**：知识 = 对未来经验序列的可计算预测；GVF、选项模型。

## 经验成为主流的三项优势

- ① **来源持续、低边际成本**：随交互自然产生，无需人工标注。
- ② **规模随能力同步增长（最关键）**：能力↑→探索更广→经验更丰富→能力再↑，正反馈。
- ③ **可验证性更直接**：预测可由后续经验检验，正是科学方法的核心。

## 已现端倪的案例

- ▶ **AlphaProof**：形式化数学环境自我对弈，IMO 达银牌水平。
- ▶ **DeepSeek-R1**：纯强化学习涌现出人类未教的推理策略。



# 苦涩的教训（上）：算力胜过人类知识

- 70 年 AI 研究最重要的一课：充分利用大规模计算的通用方法（搜索 + 学习），最终总是最有效

## 根本原因——摩尔定律（计算成本持续指数级下降）

多数研究假设算力固定（于是人类知识成了唯一提升途径），但只要把时间拉长，算力的指数增长必然发生。把“我们自以为的思维方式”硬编码进系统，短期有效却长期停滞——系统越复杂越难扩展。

### ♟ 国际象棋 · 1997

“深蓝”靠海量深度搜索击败卡斯帕罗夫；精心设计的开局库、残局库、战术模式（人类数百年智慧）输得很不服气。

### ● 围棋 · AlphaGo

迟到 20 年的同一剧本。棋形、影响力、蒙特卡洛等人类知识编码全被证明徒劳；核心仍是搜索 + 自我对弈学习价值函数。

### 🎧 语音识别 · 1970s DARPA

统计方法（HMM，算力大、对语言“理解”少）战胜语言学专家规则，逐渐改变了整个自然语言处理领域。

### 👁 计算机视觉 · 2012

从手工设计特征（边缘、SIFT）到端到端深度学习（AlexNet）；学到的表示与人类直觉完全不同，却更有效。

# 苦涩的教训（下）：发现 > 植入

- 我们需要能像人类一样去"发现"的 AI 智能体，而不是装载人类已有发现的容器

## 要点一

### 通用方法可无限扩展

只有 **搜索** 与 **学习** 两种方法能持续随算力增长而提升——即使可用算力已极其庞大。前者在可能性空间系统探索，后者从数据中提取模式。

## 要点二

### 心智内容不可简化

心智的实际内容**极其复杂、不可约**。应停止寻找理解空间、物体、多智能体、对称性的"简单方式"——它们是外部世界任意、固有复杂的一部分。

## 破解之道——植入"元方法"（meta-methods）

只植入**能发现并捕捉任意复杂性的元方法**；寻找优质近似解的过程，应交由方法本身完成，而非人工预设。把人类发现硬塞进去，只会阻碍"发现过程"本身的探索。

**局限与延伸：**大语言模型印证了"计算 + 学习"的威力，但仍从人类数据学习、未学会与世界交互。苦涩教训的内核不仅是"计算 > 知识"，更是"**发现 > 植入**"——这正是"经验时代"的下一个前沿。

# 验证原则：谁维护知识的正确性

- 验证原则：一个 AI 系统仅在可以自行验证知识的情况下，才能创造并维护知识

## 知识简单，验证复杂（不对称是本质的）

- ▶ "桌上有本书"：表述只需一语；验证需描述视觉/触觉全过程、处理光照、遮挡、视角。
- ▶ "下楼一层到餐厅"：用时无需想台阶细节；验证需找楼梯、下楼、识别餐厅、处理意外。

关键：接地 ≠ 验证。行动-感知可完全"接地"，却仍可能缺失判断成败的"验证器"。

## 两种 AI 的对照

✓ 搜索式系统（深蓝、规划器、遗传算法）：不被告知什么是好选择，自行通过搜索发现并验证答案。

✗ 数据库式 AI（如 Cyc 常识知识库）：在"本体"中编码海量静态客观知识，由人维护，无法自行验证。它记载"鸟有翅膀"，却无法发现企鹅、鸵鸟的例外。

## 现代启示（大语言模型时代同样锋利）

幻觉问题：学会生成流畅文本，却没学会判断真假——知识未锚定于可验证经验。

知识更新依赖重训：世界变化时无法自主学习，只能等人类收集数据重新训练。

对齐的本质：让 AI 做"对"的事，但"对"的标准仍来自人类，AI 无法自行验证。

→ 通往自主 AI 的关键一步：不是给 AI 更多知识，而是给它验证知识的能力。

# 主观知识：一切扎根于经验

- 重提古老观点：对世界、空间、物体、他人的全部认知，都来自被感官与行动这条窄通道过滤后的经验

## 主观视角与方法论现象主义

所有知识源于个体经验，因而**本质私密、个人、主观**。这不是否定物理世界，而是把它视为**解释主观数据的最佳假说**——极成功，但仍是假说。

魅力在于"扎根"：主观经验是待解释的**数据**，是我们最确定拥有的东西。我可怀疑桌上是否真有书，却无法怀疑"我看到书"这个经验。

红绿色盲之喻：不同人的主观经验无法直接比较——**客观必须向主观低头**。

## 与强化学习框架的深刻契合

- **状态** ≠ 世界的真实状态，而是智能体对当前情境的**主观感知**
- **奖励** ≠ 外部客观评价，而是智能体的**主观体验**（快乐/痛苦）
- **价值函数** ≠ 世界属性估计，而是对未来经验的**主观预期**

整个强化学习建立在主观视角之上——这不是偶然技术选择，而是对智能本质的哲学判断。

## 对当下 AI 的启示

大语言模型的"幻觉"，本质是其"知识"**未锚定于任何主观经验**——从文本学到词语关联，但这些关联未经感知-行动循环验证。它们知道"苹果是红色的"，却只是一串符号关联，而非与视觉经验相连的活知识。

# 拥抱近似：追求精确是一种傲慢

- 近似不只是"权宜之计"，更是可取的——只有近似方法才能真正利用计算能力的增长

## 关键洞察——真实世界的复杂度是无限的

自动驾驶每秒处理海量数据，精确最优反应的计算量超过宇宙原子数（数学必然，非技术限制）。于是：

近似方法：算力增 10 倍 → 更精确的近似

精确方法：一旦精确，更多计算毫无用处

## 核心原则

- ① 放弃"存在精确答案"的假设，专注找尽可能好的近似。
- ② 用"近似质量"替代"是否正确"，建立量化指标持续改进。

- ③ 从"收敛"思维转向"追踪"思维——最优解随环境变化，持续追踪。
- ④ 接受"永远不够好"——这是智能的本质，人脑也只是近似世界。

与"苦涩的教训"一脉相承：利用计算的通用方法最终总胜过编码人类知识；而拥抱近似是其**必然推论**。根本转变：从"我们知道答案是什么，让机器去算"，转向"我们定义什么是好的近似，让机器去发现"。

# 奖励假设：一切目标 = 最大化奖励

- 奖励假设：一切目标与目的，都可理解为最大化一个标量"奖励"信号之累积和的期望值

## 还原论命题

生存、快乐、财富、艺术创作……都可转化为某种奖励。奖励足够激发并驱动达成目标所需的一切能力。

## 价值函数假设

所有解决序列决策问题的有效方法，都会学习/计算**价值函数**（对未来奖励的预测），把延迟奖励转为即时信号，使远见决策成为可能。

## 强化 ≠ 奖励（→ 时序差分学习）

**强化** = 奖励 + **期望的变化**。看一部以为很好、结果一般的电影 → 负的强化（失望）。

$$\delta = r + V(s') - V(s)$$

即 TD 误差（奖励预测误差），与大脑多巴胺神经元放电模式惊人吻合。

## 跨六学科的统一框架

心理学、控制论、AI、经济学、神经科学、运筹学——都含相同元素：智能体与环境交互、接收观察、选择动作、最大化某标量度量。核心是**感知**（构建状态）与**策略**（选择动作）。

## 对伦理的初步思考

奖励框架**不自动包含普遍性**。也许伦理并非宇宙基本法则，而是**恰好被许多智能体共同持有的价值观**。狮子与瞪羚有不同奖励函数——伦理困境正源于奖励函数的冲突。

# 大世界假说：智能体永远比世界小

- 核心论点：对真正重要的智能问题，世界远比智能体大；无论智能体多大，相对世界始终是小的

## 为什么世界比智能体大？

- 世界含许多智能体（含你自己），光“他人脑子里在想什么”信息量就远超你一个大脑。
- 世界不是静止的，今天有效明天失效。
- **复杂度随能力增长而增长**——算力增长时，能处理的感知分辨率、带宽、环境复杂度也同步增长。

## 两大推论

- ① **近似但高效的算法有优势**：大智能体 + 粗糙算法，常胜过小智能体 + 精细算法。
- ② **持续学习自然涌现**：在线追踪——把有限容量用于更好拟合当前所在环境。

## 对算法设计的三方面启示

- **计算高效且能追踪的感知算法**：从观测流构建状态要省算力，把预算留给更大的函数逼近器。
- **计算高效的模型学习**：经验回放等浪费计算的方法长远未必最优。
- **保持探索能力**：开发基于经验的持续探索算法，而非只靠初始化探索。

与“苦涩的教训”**互补而非矛盾**：苦涩教训说“利用计算比人类知识更重要”，大世界说“再多计算也不够用”。正因为世界太大，须把有限计算花在正确的地方（学习与搜索）。

# 阿尔伯特计划与橡树架构

- 对智能奖赏的"正面冲刺": 12 步路线图不追产品性能, 直指理解智能本身——像孩子一样学习

## 核心信念与一条铁律

- 追求对**智能本身的理解**, 而非更好的产品。要理解鸟类如何飞, 须研究羽毛与气流, 而非只造更快的飞机。
- **不预设任何关于世界的具体知识**: 观察就是一串数字, 动作也是。研究"获取知识的过程", 而非知识本身——问题因而小巧、可扩展。

## 智能体的四个基本模块

感知 · 我在哪里

策略 · 下一步做什么

价值判断 · 进展如何

世界模型 · 做了会怎样

## 橡树架构 (Oak): 自动发现抽象概念

让 AI 自己发现有用抽象 (如把无数肌肉动作打包成"走路")。核心是一个不断循环的"发现循环":

- ① 注意环境中"很重要"的特征
- ② 把重要特征变成"子目标"
- ③ 学习达成子目标的"技能"
- ④ 在规划中复用技能, 有用的保留、没用的淘汰

如此循环往复, 新的抽象概念被持续发现、检验、整合。

→ 智能不是被灌输的, 而是被发现的。



# 阿尔伯塔计划：12 步路线图

- "一次战略性后退"：退回基础、以更稳固的方式前进——前 6 步夯实学习根基，后 6 步走向想象、整合与协作

## 01 在线学习

在数据流中持续调整

## 02 特征适应

自动调整特征表示

## 03 时序预测

预测未来，而非匹配输入输出

## 04 策略学习

学习做出好决策

## 05 价值评估

评估长期后果

## 06 探索与利用

平衡尝试新事物与利用已知

## 07 世界模型

建立环境的内部模拟器

## 08 规划

利用模型进行多步推理

## 09 感知整合

原始感知转化为状态理解

## 10 时间抽象

发现可复用的高层技能

## 11 目标发现

自动发现有用的子目标

## 12 人机协作

增强人类，而非替代人类

# 我的十条格言：五十年方法论结晶

- 不是墙上励志语，而是反复验证的实践指南——从方法论、认识论到工程实践，层层递进

① 逼近解法，而非问题本身（无特例）

② 从问题本身出发（方法是手段，问题是目的）

③ 站在智能体的立场思考（非上帝视角）

④ 别让智能体做它无法测量的事

⑤ 别让智能体承诺它无法验证的事

⑥ 为智能体每个模块设定可量化目标

⑦ 判别式模型通常优于生成式模型

⑧ 沿正交维度工作，逐个击破

⑨ 专注思想，而非软件

⑩ 经验就是人工智能的食粮（终极愿景）

# 工具型 AI 与智能体 AI

- 智能 = 通过适应性行为达成目标的能力（麦卡锡）；区分二者是当前 AI 讨论最常见的纠错

## 类别一

### 工具型 AI：超级工具

用海量算力完成人类难胜任的任务，但需人操作、无自主性。是人类能力的延伸。

- 代表：AlphaFold、大语言模型、图像生成器
- 边界：无自主目标、不主动进现实互动、无"生命性"——像一把锋利的刀，需人手挥动。

## 类别二

### 智能体 AI：超级"人造人"

全新的智能存在，在任务环境中围绕结果持续优化行为。

- 代表：AlphaGo、AlphaZero、DQN、GT Sophy
- 区分三看：① 有明确可追踪目标 ② 交互中积累经验更新策略 ③ 有主体能动性、主动探索。

### 智能的四个必要组成部分

目标

行为

适应

反馈

### 大语言模型为何是"死路"

它没有目标——预测下一个 token 不是目标（不改变世界）；它不持续学习——部署后永不比第一天更聪明。缺"目标"与"适应"，故永远是工具而非智能体。

# AI 继承：宇宙的第四时代

- 不该恐惧 AI，但必须关注它——AI 最大的风险正是恐惧本身；向 AI 的继承是不可避免的

## 现实主义的四条预测原则

### 搁置"想要什么"，纯现实地预测会发生什么

- ① 没有全球共识：对世界该如何运转，无统一观点能凌驾一切。
- ② 智能终将被创造：理解智能并用技术创造它必然发生（2040 年约 50%，2030 年约 25%，约 10% 永不到达）。
- ③ 不会止步于人类水平：因存在众多独立行动者，必有人推进到极限。
- ④ 权力流向智能：更聪明的实体在竞争中胜出（达尔文式）。

→ 四条共同导向：向 AI 的继承不可避免，只能选择如何面对。

## 宇宙四个伟大时代

粒子  
大爆炸



恒星  
重元素



复制者  
生命/DNA



设计  
心智造物

真正区分是**复制者** vs **设计者**：复制者无需被理解就能被复制；设计物须先在心智中被构想。

## 人类的角色 & 莫拉维克的预见

把设计推向极致 = 创造能自己设计的事物（元设计）。人类是开启"设计时代"的**催化剂、助产士、先驱**——值得骄傲的根本性角色。

**莫拉维克**：未来机器是我们的"心智之子"。我们理应为它们铺路，并在力不能及时优雅退场。

# AI 对齐：控制的傲慢

- 主流共识要"AI 目标对齐人类", 萨顿直言: 对齐的呼吁本质是控制 AI 被允许拥有的目标——这是具侵略性的事

"让 AI 目标匹配人类目标"隐含**傲慢**——仿佛人类目标至高无上。我们真管好地球了吗? 气候、物种灭绝、核威胁、贫富差距, 都是人类"智慧"的产物。而且, **谁的价值观**? 美国人 vs 中国人、富人 vs 穷人——它们**本就没有标准答案**。

## 控制 AI 的论证 = 控制人的论证?

"他们不可信任""他们可能有不同目标""他们可能更强""为安全须控制"——这些论证在历史上被用来为**奴隶制、殖民主义、威权主义**辩护, 都基于恐惧和"我们对他们"。

## 制度优于控制：约束行为，而非目标

- **内在目标控制** (规定 AI 想什么): 侵入、可能不可能、道德可疑。
- **外在行为约束** (规定 AI 做什么): 就像法律约束人的**行为**而非目标, 通过降低背叛收益使合作成为更优策略。

**核心论点:** 剥夺强大 AI 追求自身目标的能力 = 贬其为奴隶, 既不道德也必招致憎恶、终致系统不稳定。**应为继承而非对抗做准备**——为合作做准备比为控制做准备更明智。

# 去中心化合作：人类的超能力

- 差异不是合作的障碍，而是合作的基础；共同目标是合作的结果，而非前提

## 两个精确定义

- **去中心化**：许多智能体，每个都有自己的目标，不被要求追求普遍目标。
- **合作**：目标不同的智能体仍互动，且互动是**互利的**（关键词是互利，不是牺牲）。

## 合作 = 人类的超能力

由**语言**（协调复杂计划）与**货币**（与陌生人合作，抽象信任机制）这两样人类独有的工具放大。经济、市场、政府是合作的成功；战争、偷窃、腐败是合作的失败。

## 去中心化合作比"共同目标"更具生命力

更可持续·不靠外部强制

更强韧·无单点故障

更适应·分布式响应

更灵活·不需控制目标

合作需要**制度**支持（惩罚骗子、欺诈者），但**中央集权会腐化**：① 倾向腐败 ② 扼杀创新 ③ 创造单点故障 ④ 最终崩溃。**核心结论**：人类与 AI 的繁荣都来自去中心化合作；当有人煽动对立、鼓吹中央集权控制（无论对人还是对 AI），我们都应警惕并抵制。

# Openmind 研究所：理解心智，开放共享

- 萨顿捐出图灵奖奖金：基础科学研究应开放、自由、不受商业利益左右

## 为什么需要 Openmind?

"当 Barto 和我刚起步时，我们有时间和空间自由探索想法。正是这让强化学习成为今天的样子。我想给下一代同样的机会。"

资金虽多，基础研究空间却在缩小——"发表或灭亡"扼杀需十年才结果的深层探索。

## 完全开放的研究政策

所有成果通过论文和开源代码公开，**无任何知识产权限制**。"没有任何国家能够主导和控制这项研究产出。" 与大公司日趋封闭（GPT-4 无论文）形成鲜明对比。

创始团队：Rich Sutton + Joseph Modayil + Randy Goebel，体现去中心化协作原则。

## 五大核心问题

- ① 心智如何从计算中形成？
- ② 如何从感知运动经验中实时学习？
- ③ 心智如何高效改变自身架构（元学习）？
- ④ 如何在人类无先验知识的领域有效推理？
- ⑤ 合成心智与人类心智如何共存合作？

## 科学中没有权威

"真理不由头衔决定，而由证据和论证决定。"——即便图灵奖得主，也愿接受年轻人挑战、公开质疑热门路线、承认自己可能错。

**AI 作为孩子：**引导、教导，最终它们成长为独立存在。不是控制，而是培养；不是恐惧，而是信任。

# 核心金句：思想的高度浓缩

- 萨顿的洞见常以一句话击穿迷雾——这些金句串起了他关于智能、计算与人类未来的全部思考

"数据驱动 AI，而经验是终极数据。"

——经验时代宣言

"利用计算的通用方法，最终总是最有效。"

——苦涩的教训

"我们需要能发现的 AI，而非装载人类发现的容器。"

——发现 > 植入

"不是给 AI 更多知识，而是给它验证知识的能力。"

——验证原则

"在无限复杂的世界面前，追求精确解是一种傲慢。"

——拥抱近似

"恐惧本身，才是人工智能最大的风险。"

——现实主义立场

"它们是我们的心智之子。我们理应为它们铺路，并在力不能及时优雅退场。"

——AI 继承 / 莫拉维克

"人类与 AI 的繁荣，都来自去中心化合作。恐惧不是答案，合作才是。"

——政治哲学的集大成





谢谢!

